Нейросетевая обработка данных в ГИС GRASS и R

Совместного использования ГИС GRASS и статистического пакета R.

Данная статья продолжает публикацию Анализ данных с использованием GRASS GIS и R, посвященную теме совместного использования ГИС GRASS и статистического пакета R.

Обсудить в форуме Комментариев — 0

В данной статье рассматривается пример использования нейросетевого пакета AMORE и анализ данных в ГИС GRASS.

Оглавление

1. Описание задачи

Процесс нейросетевого анализа данных GRASS GIS рассмотрим на примере конкретной задачи:

Описание задачи: даны снимки одной и той же территории, сделанные в разное время. Предполагается, что некоторая (в процентном соотношении небольшая) часть территории за время, прошедшее между съемками, подверглась изменению. Нужно определить участки изменений.

Ход решения: берем пару последовательных снимков и строим регрессию - по первому снимку предсказываем значения второго снимка. Условие того, что изменению подверглась незначительная часть территории позволяет надеяться, что:

- предсказание второго снимка по первому может быть довольно точным
- те участки, для которых заметно значительное расхождение предсказанного и реального значений и есть изменившиеся участки.

Регрессию будем строить при помощи нейронных сетей. Данные, предназначенные для анализа хранятся в проекте GRASS, используемые снимки - MODIS (используются два канала - (1) красный и (2) ближний инфракрасный). Рассматриваются две даты: 3 апреля 2000 года и 12 июля 2000 года и территория заповедника Черные Земли.

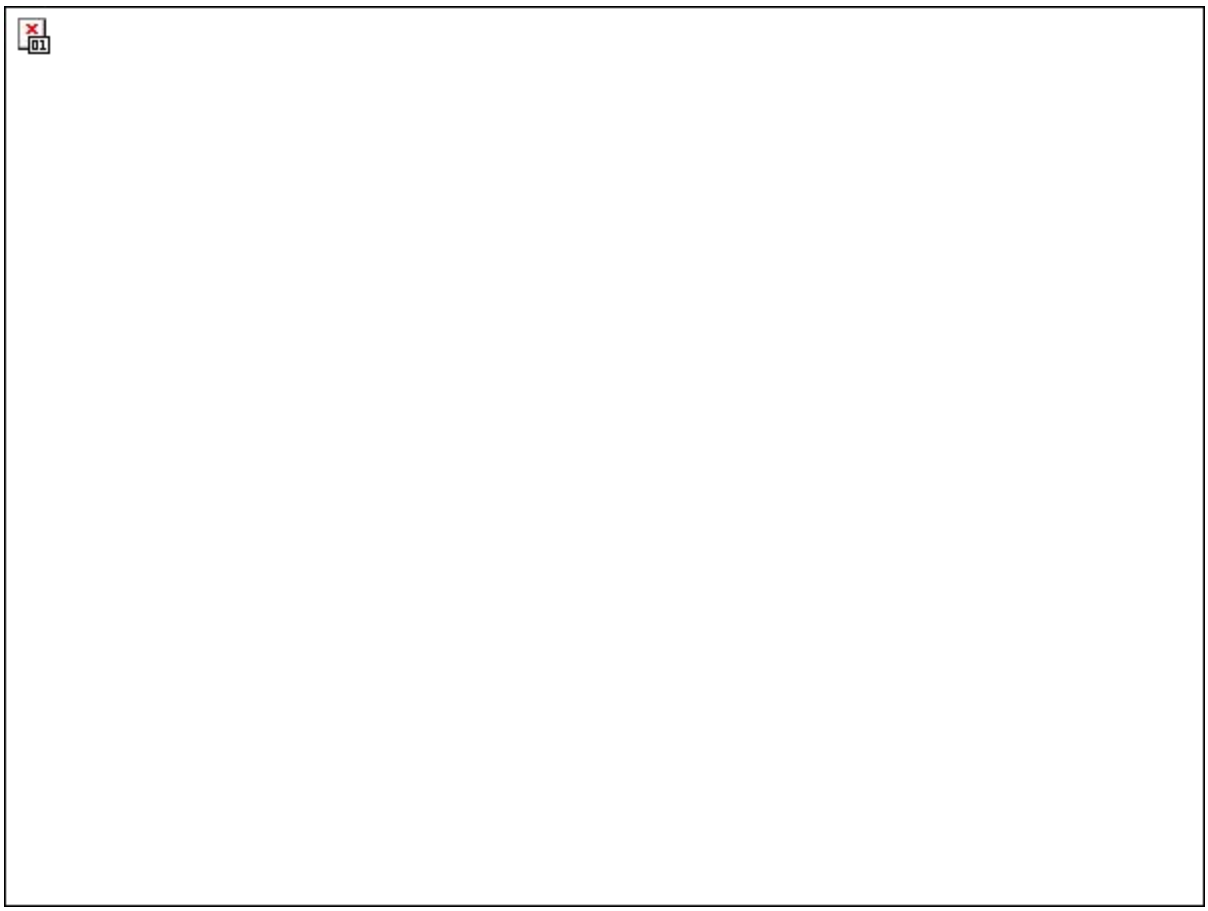

Композитное RGB изображение 1-2-1, 3 апреля 2000, данные MODIS

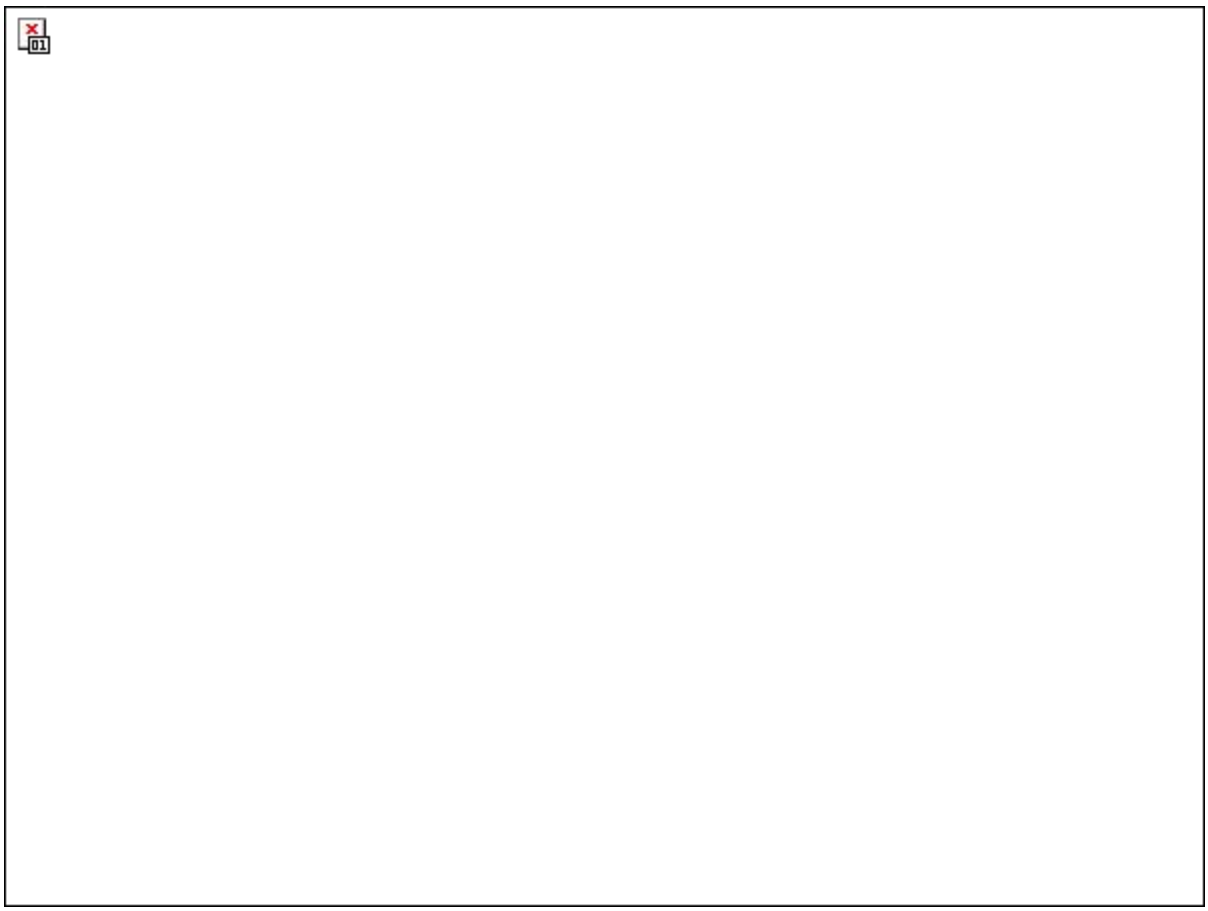

Композитное RGB изображение 1-2-1, 12 июля 2000, данные MODIS

Т.о. действовать будем следующим образом:

1. Предобработка данных: производится в GRASS.
2. Построение нейронной сети: производится в R.

3. Постобработка данных и анализ результатов: производится в GRASS.

2. Реализация

Предобработка

Будем строить многослойный перцептрон, который берет на входе значения первого и второго каналов снимков от 3-го апреля, а на выходе возвращает предполагаемые значения первого и второго каналов для снимков от 12-го июля. Функцию активации нейронов возьмем сигмоидального типа:

$$f(u) = 1/(1+ \exp(-u)).$$

Перед построением сети необходимо предварительно пронормировать данные. Выходные значения должны быть нормированы к диапазону изменения функции активации (0, 1), входные же значения нормировать хотя и не обязательно, но, тем не менее, очень желательно.

Конкретный вид нормирующей функции становится ясен после анализа гистограммы распределения входных и выходных данных. В качестве примера возьмем данные по второму каналу каждого снимка:

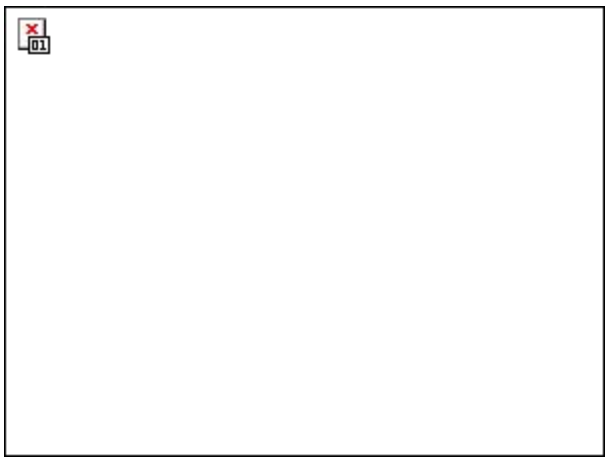
Гистограмма для второго канала (3 апреля)

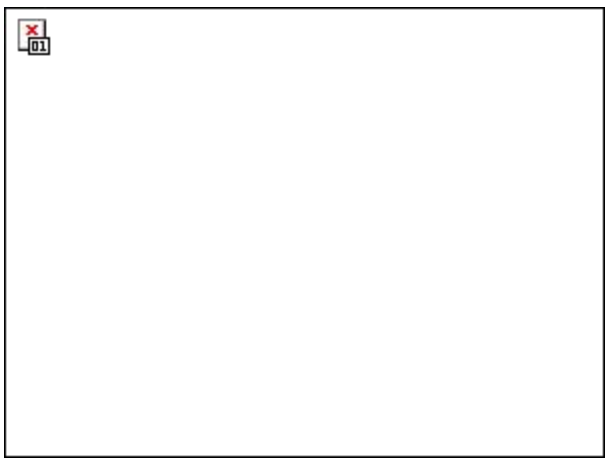
Гистограмма для второго канала (12 июля)

Как видим, первая гистограмма близка к нормальной, поэтому воспользуемся линейной нормировкой с использованием статистических характеристик. Более конкретно, пронормируем данные соответсвующего снимка по формуле:

$$X = (x - m)/s$$

Здесь X - нормированное значение, x - исходное значение, m - среднее значение, s - стандартное отклонение.

Со вторым снимком дело обстоит немного сложнее: на гистограмме явно видны длинные хвосты слева и справа, соответственно, линейное нормирование к диапазону (0, 1) приведет к тому, что почти все данные будут сгруппированы в небольшом интервале. Чтобы избежать этого воспользуемся нормировкой при помощи функции активации:

$$X = f(x - m)/s$$

Здесь X - нормированное значение, x - исходное значение, m - среднее значение, s - стандартное отклонение, f - функция активации нейронов.

С первым каналом дело обстоит аналогично.

Реализация нормирования в GRASS GIS:

- Посмотрим статистику по первому каналу для снимка от 3-го апреля:

```
r.univar A2000.092.1 -g

n=699312
null_cells=748326
cells=1447638
min=582
max=4169
range=3587
mean=1505.60636025122
mean_of_abs=1505.60636025122
stddev=347.104721534699
variance=120481.687711681
coeff_var=23.0541481956002
sum=1052888595
```

- Пронормируем:

```
eval `r.univar A2000.092.1 -g`
r.mapcalc "norm_A2000.092.1 = (A2000.092.1 - $mean)/$stddev"
```

- Посмотрим на результат:

```
r.info norm_A2000.092.1
 +----------------------------------------------------------------------------+
 | Layer:    norm_A2000.092.1               Date: Thu Jan  6 17:22:46 2011    |
 | Mapset:   PERMANENT                      Login of Creator: dima            |
 | Location: fires                                                            |
 | DataBase: /home/dima/laboro/GRASSDATA                                      |
 | Title:     ( norm_A2000.092.1 )                                            |
 | Timestamp: none                                                            |
 |----------------------------------------------------------------------------|
 |                                                                            |
 |   Type of Map:  raster               Number of Categories: 255             |
 |   Data Type:    DCELL                                                      |
 |   Rows:         1333                                                       |
 |   Columns:      1086                                                       |
 |   Total Cells:  1447638                                                    |
 |        Projection: Albers Equal Area                                       |
 |            N: 4755751.76759771    S: 4422409.14242904   Res: 250.06948625  |
 |            E: 8747582.56252927    W: 8476175.04184751   Res: 249.91484409  |
 |   Range of data:    min = -2.660887  max = 7.673170                        |
 |                                                                            |
 |   Data Description:                                                        |
 |    generated by r.mapcalc                                                  |
 |                                                                            |
 |   Comments:                                                                |
 |    (A2000.092.1 - 1505.6064) / 347.10472                                   |
 |                                                                            |
 +----------------------------------------------------------------------------+
```

Аналогично поступим с остальными снимками:

```
eval `r.univar A2000.092.2 -g`
r.mapcalc "norm_A2000.092.2 = (A2000.092.2 - $mean)/$stddev"

eval `r.univar A2000.192.1 -g`
r.mapcalc "norm_A2000.192.1 = 1/(1 + exp(- (A2000.192.1 - $mean)/$stddev))"

eval `r.univar A2000.192.2 -g`
r.mapcalc "norm_A2000.192.2 = 1/(1 + exp(- (A2000.192.2 - $mean)/$stddev))"
```

В качестве примера ниже приводится гистограмма для нормированного второго канала (12-е июля):

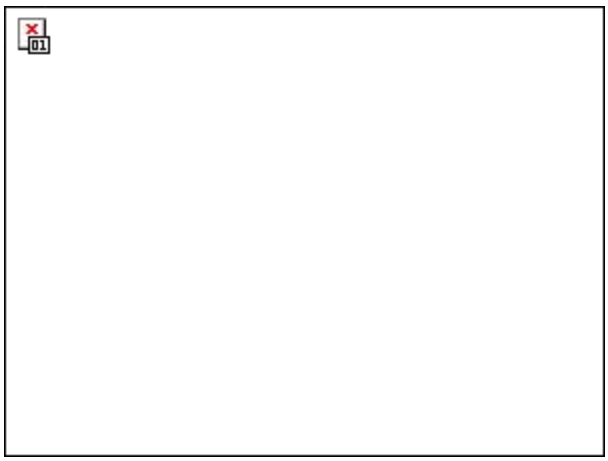
Гистограмма нормированного снимка

Построение нейронной сети

Загружаем R из-под GRASS GIS и считываем данные (дальнейшие команды вводятся в сеансе R):

```
library(spgrass6)
in1 = readRAST6('norm_A2000.092.1')
in2 = readRAST6('norm_A2000.092.2')
out1 = readRAST6('norm_A2000.192.1')
out2 = readRAST6('norm_A2000.192.2')
```

Создадим data.frame, содержащий считанные данные, и почистим его от пустых значений:

```
d = data.frame(in1 = as.vector(as.matrix(in1)), in2 = as.vector(as.matrix(in2)), out1 =
as.vector(as.matrix(out1)), out2 = as.vector(as.matrix(out2)))
d=d!is.na(d$in1),
d=d!is.na(d$out1),
```

Разобъем данные на обучающее и валидационное множества, в обучающее множество поместим приблизительно 2/3 примеров:

```
len = length(d,1)
val.ind = sample(1:len, size = len/3)
val = dval.ind,
train_data = d-val.ind,
```

Подгрузим AMORE - пакет для работы с нейронными сетями. (В R есть несколько пакетов, позволяющих создавать многослойные сети, пакет AMORE был выбран, в первую очередь, из-за скорости работы).

```
library(AMORE)
```

Создадим нейронную сеть. Поскольку данных для обучения имеется достаточное количество (около 700 тыс. пикселей), то и количество нейронов можно взять относительно большим. Для начала создадим сеть достаточно больших размеров - с двумя скрытыми слоями по 20 и 10 нейронов в каждом(2-20-10-2); функцию активации для всех нейронов выберем сигмоидальную (логистическую):

```
net = newff(n.neurons=c(2,20,10,2), learning.rate.global=0.1,
momentum.global=0.01,error.criterium="LMS", hidden.layer="sigmoid",
output.layer="sigmoid", method="ADAPTgdwm")
```

Обучим сеть в течении 500 итераций, для этого передадим процедуре обучающее и валидационное множества. На обучающем множестве будут настраиваться веса сети, валидационное использоваться для раннего останова. Полученную сеть назовем net1

```
result = train(net, P=train_data,1:2, T=train_data,3:4, Pval=val,1:2, Tval=val,3:4,
error.criterium="LMS", report=TRUE, show.step=1, n.shows=500)
net1 = result$net
```

В ходе экспериментов наиболее удачной сетью оказалась сеть с одним скрытым слоем и пятью нейронами в

нем. В результате обучения этой сети была достигнута ошибка на обучающем множестве: 0.0188, на валидационном: 0.0190.

После обучения сети произведем расчеты, подавая в обученную сеть данные первого снимка. Для этого предварительно входные данные поместим в ненужную уже переменную d, затем в переменную y поместим результаты работы сети:

```
d = data.frame(in1 = as.vector(as.matrix(in1)), in2 = as.vector(as.matrix(in2)) )
y = sim(net1, d)
```

И, наконец, последний этап, который нужно проделать в R - экспорт результатов обратно в GRASS:

```
r1 = out1
r1$norm_A2000.192.1 = y,1
writeRAST6(r1, 'net.1')

r2 = out2
r2$norm_A2000.192.2 = y,2
writeRAST6(r2, 'net.2')
```

Анализ результатов

После экспорта полученных растров в GRASS выходим из R. Прежде, чем сравнивать созданные нейронной сетью растры с реальными снимками, их нужно денормировать. Понятно, что денормировать нужно используя те же параметры среднего и стандартного отклонения, которые использовались при нормировании:

$$x = m - s*\log(1/X - 1)$$

Для этого:

```
eval `r.univar A2000.192.2 -g`
r.mapcalc "net_A2000.192.2 = $mean - $stddev * log(1/net.2 - 1)"

eval `r.univar A2000.192.1 -g`
r.mapcalc "net_A2000.192.1 = $mean - $stddev * log(1/net.1 - 1)"
```

В итоге получаем два растра net_A2000.192.1 и net_A2000.192.2, в которых содержатся значения для первого и второго канала соответственно, предсказанные нейронной сетью. Вместо того, чтобы сравнивать непосредственные значения полученных растров и снимков, будет удобно найти разности между предсказанным значением и реальным снимком:

```
r.mapcalc "razn2 = net_A2000.192.2 - A2000.192.2"
r.mapcalc "razn1 = net_A2000.192.1 - A2000.192.1"
```

Покрасим разности для удобства восприятия, используя их статистические характеристики:

```
r.colors.stddev razn2
r.colors.stddev razn1
```

Фрагменты полученных результатов приводятся на рисунках ниже. Сначала рассмотрим исходные снимки (северо-восточный фрагмент участка):

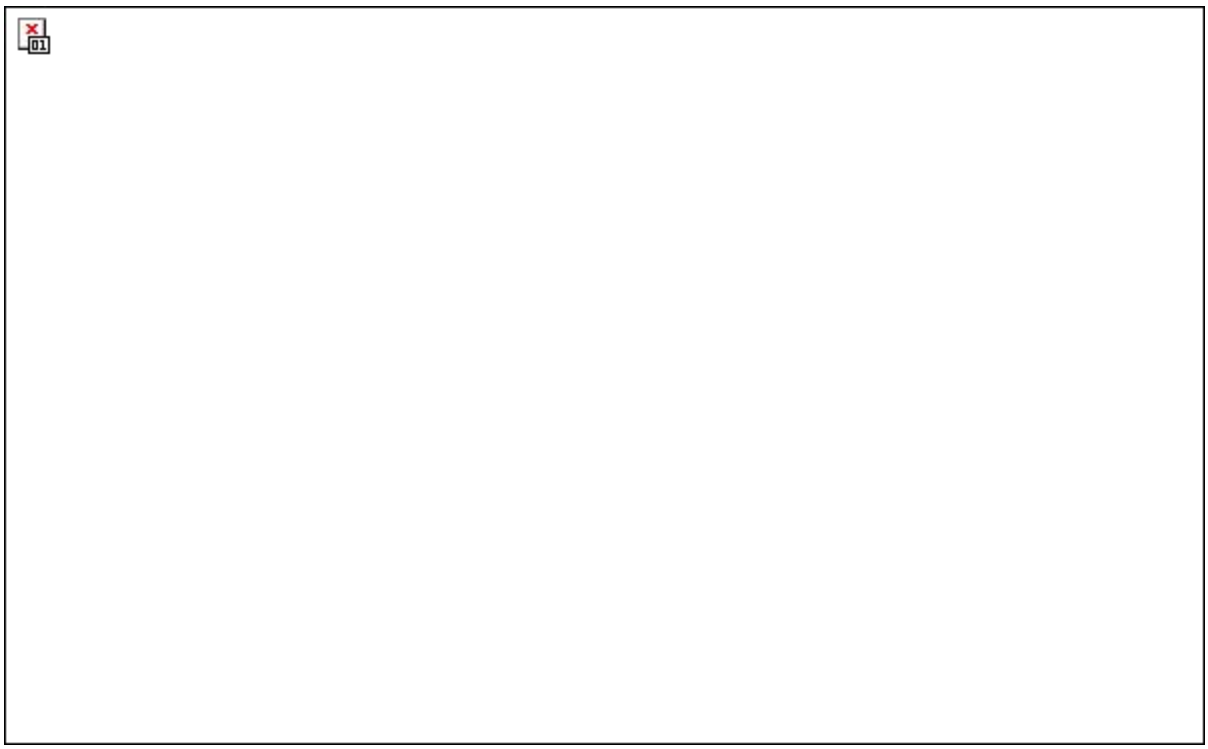

Долина Волги, 3-е апреля (rgb: 1-2-1)

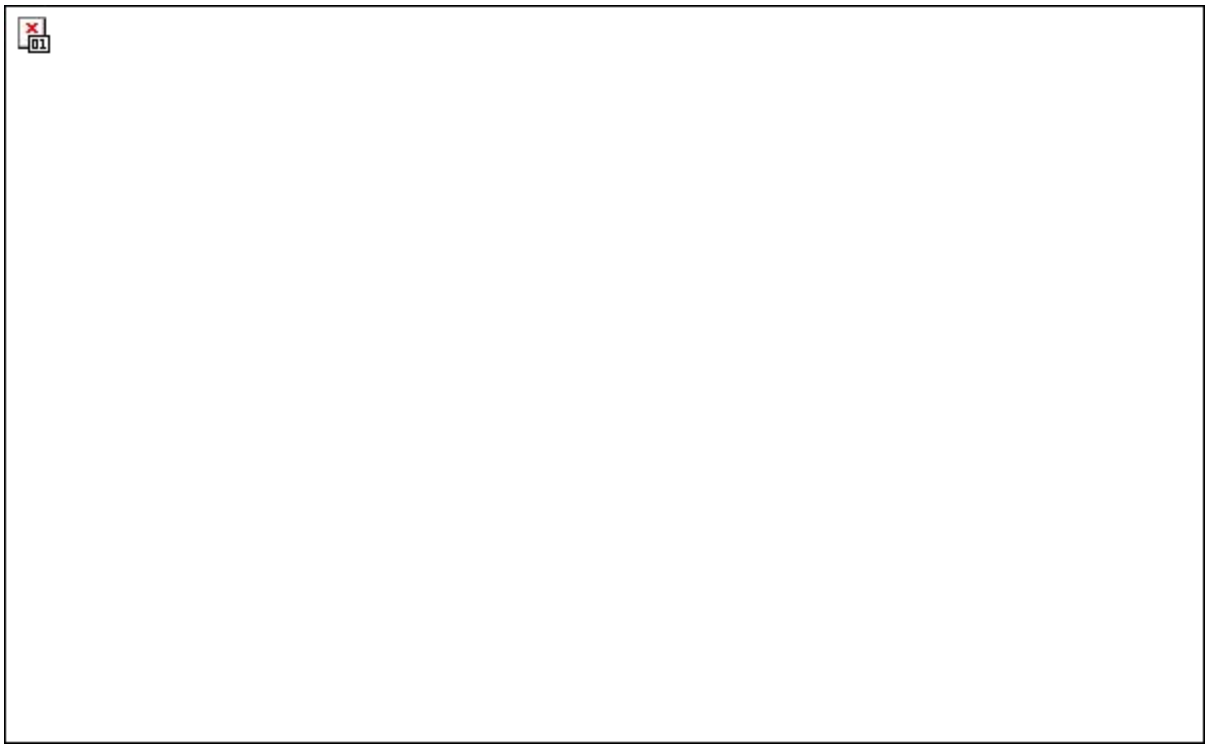

Долина Волги, 12-е июля (rgb: 1-2-1)

На снимках хорошо видно изменение растительности в долине Волги. Кроме того на позднем снимке заметна небольшая облачность. Степень различия предсказанных и реальных значений видна на растрах razn1 и razn2. Яркие участки соответствуют большим по модулю значениям разности, бледные участки - небольшим:

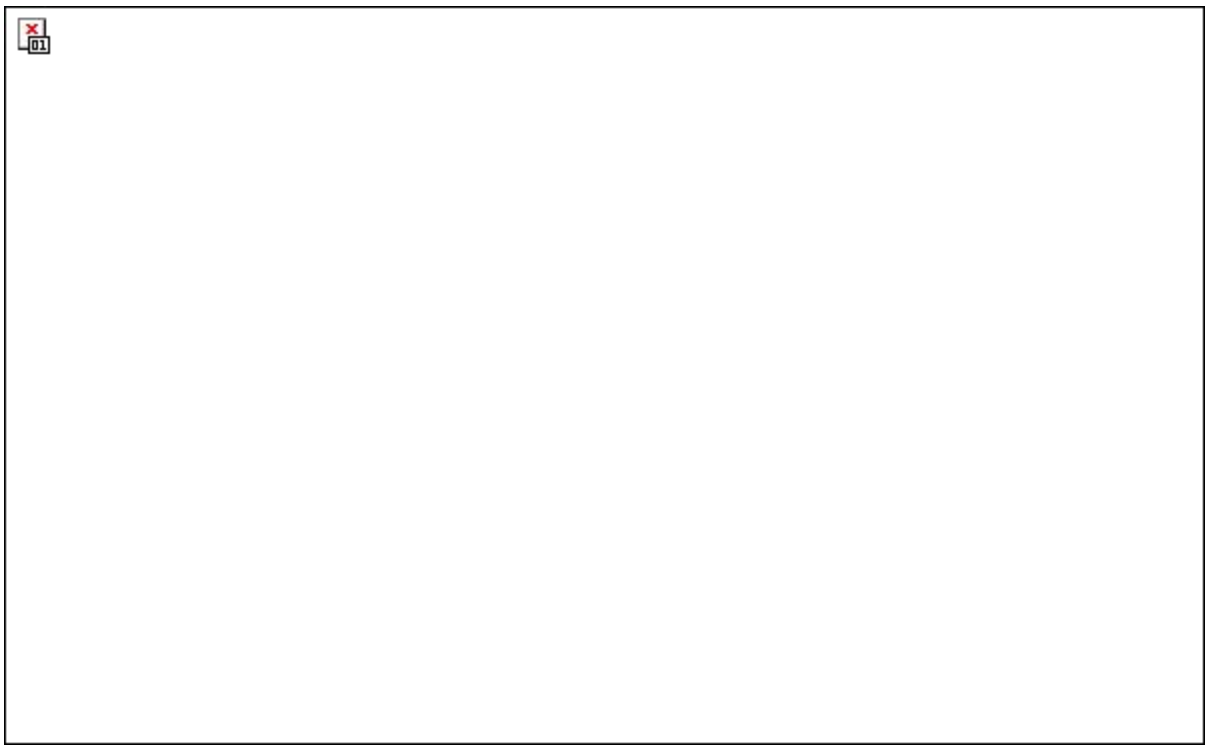
Разность (razn1

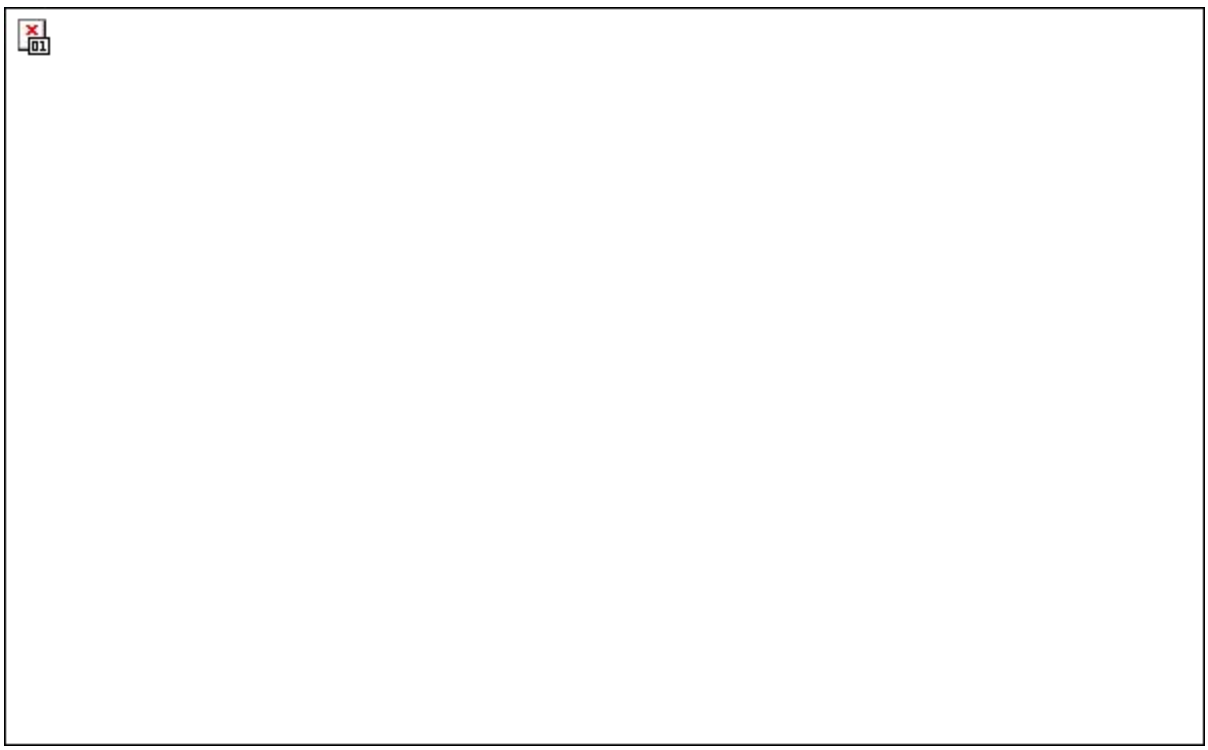
Разность (razn2)

Для удобства восприятия можно объединить две разности в один растр. Первое, что приходит в голову - перемножить их, тогда большие отклонения разностей, присутствующие на обоих растрах увеличатся еще больше, а малые - уменьшатся:

```
r.mapcalc "razn = razn1 * razn2"
r.colors.stddev razn
```

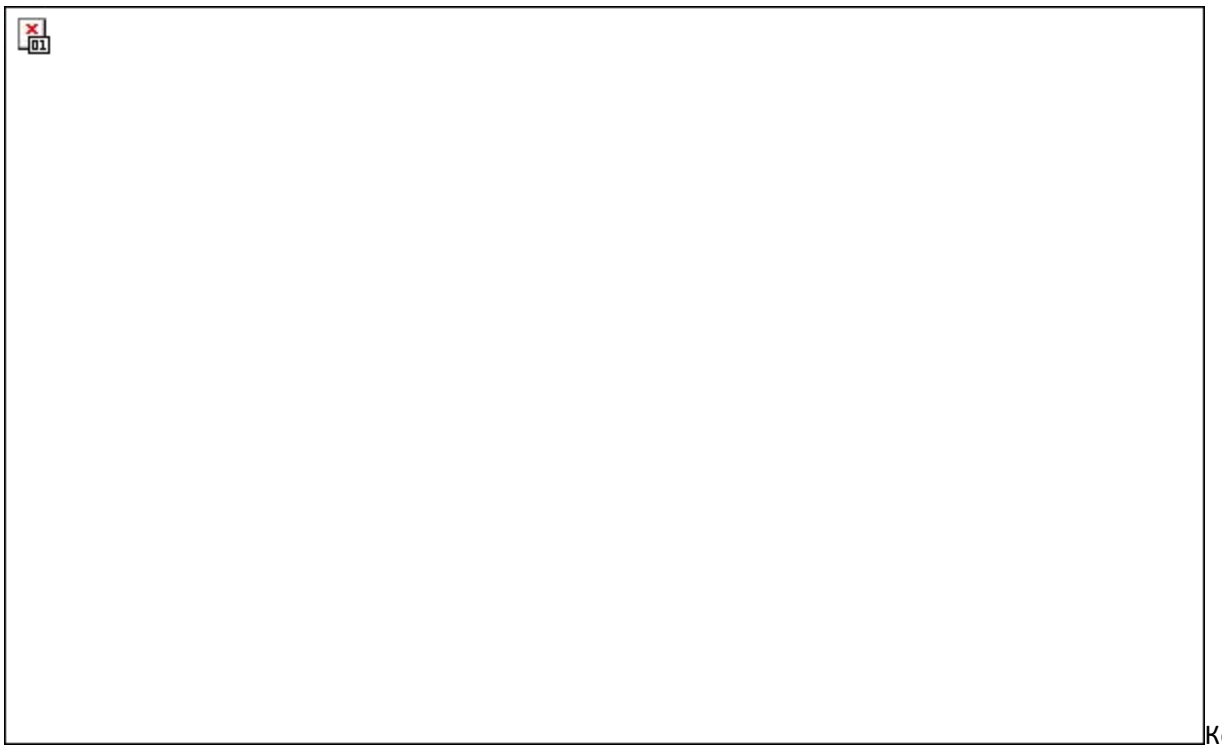
Комбинация razn1 и razn2

На полученном таким образом объединенном снимке более четко видны границы изменений: растительность в долине Волги, а также облака, появившиеся на втором снимке.

Обсудить в форуме Комментариев — 0

Ссылки по теме

- Анализ данных с использованием GRASS GIS и R

Последнее обновление: February 21 2011

Дата создания: 09.01.2011
Автор(ы): Дмитрий Колесов, Максим Дубинин